

Segmentación y conteo automático de hojas en plantas de maíz (*Zea mays L.*) mediante fenotipado de alta resolución en ambiente controlado

^aGallego Carvajal, Susana; ^bLondoño Londoño Mejía, Luciana; ^cGómez Correa, Samuel

^aIngeniería agronómica, EAFIT, Medellín, Colombia, sgallegoc4eafit.edi.co

^bIngeniería agronómica, EAFIT, Medellín, Colombia, llondonom4@eafit.edu.co

^cIngeniería agronómica, EAFIT, Medellín, Colombia, sgomezcl8@eafit.edu.co

1. Introducción

La agricultura moderna enfrenta el desafío de alimentar a una población mundial creciente con recursos naturales cada vez más limitados. En este contexto, el maíz (*Zea mays L.*) ocupa un lugar estratégico, pues representa uno de los tres cultivos más importantes del planeta en términos de producción (Tardieu *et al.*, 2017). Colombia, destina amplias extensiones a su cultivo en climas cálidos y medios, donde la arquitectura foliar de la planta determina el rendimiento final del grano.

Históricamente, la caracterización morfológica del maíz (el conteo de hojas, la estimación del área foliar, la detección del estado fenológico) ha dependido de labores manuales en campo, sujetas a error humano y una alta variabilidad entre observador (Scharr *et al.*, 2016). Por ello, aparecen como solución flujos de trabajo con inteligencia artificial que permitan reducir los errores y aumentar la efectividad.

Así, el procesamiento digital de imágenes y la visión por computadora ofrecen una vía prometedora para superar dicha limitación mediante algoritmos de segmentación, es posible separar automáticamente los píxeles correspondientes a la planta de su fondo; a través de técnicas de esqueletización, se puede extraer la estructura topológica de la planta y con métodos de conteo basados en puntos de ramificación del esqueleto, se puede determinar el número de hojas de forma objetiva, rápida y reproducible (van der Walt *et al.*, 2014).

El presente proyecto propone una metodología computacional integral, implementada en Python, que integra estas tres etapas sobre la muestra del Maize Whole Plant Image Dataset publicado por INRAE en 2017, con el fin de demostrar la viabilidad técnica del enfoque y sentar las bases para su aplicación en contextos reales de fenotipado de alto rendimiento.

2. Contexto del Problema

La fenología del maíz está estrechamente ligada a la morfología foliar (Brichet *et al.*, 2017). Conocer el número exacto de hojas desplegadas en un momento dado permite al agrónomo estimar la etapa

vegetativa de la planta, predecir la fecha de floración y calibrar las dosis de fertilización nitrogenada, que en maíz son marcadamente dependientes del estadio fenológico.

Bajo condiciones de estrés hídrico, la emisión de estigmas (sedas) y el crecimiento del esquilmo están regulados por la velocidad de expansión foliar (Tardieu *et al.*, 2017). Plantas con menor área foliar acumulada interceptan menos radiación fotosintéticamente activa, comprometiendo el rendimiento.

A pesar de los avances tecnológicos, los sistemas de fenotipado automatizado siguen siendo costosos y de difícil acceso para los pequeños y medianos productores. El desarrollo de análisis de imagen de código abierto busca democratizar el acceso a herramientas de fenotipificación y contribuye a cerrar la brecha tecnológica que separa a los países en desarrollo de las naciones con mayor tradición agroindustrial.

3. Descripción de la Base de Datos

El dataset Maize Whole Plant Image Dataset fue publicado en octubre de 2017 por Nicolas Bricchet y Llorenç Cabrera-Bosquet, investigadores del Institut National de Recherche pour l'Agriculture, l'Alimentation et l'Environnement (INRAE, Francia).

El conjunto de datos contiene 1482 imágenes RGB de plantas de maíz completas, capturadas en la plataforma de fenotipado de alta resolución PHENOARCH, ubicada en Montpellier, Francia. (Bricchet *et al.*, 2017) Cada imagen tiene una resolución de 2448×2048 píxeles y fueron tomadas desde múltiples ángulos de visión lateral, permitiendo una cobertura tridimensional de la planta. Las imágenes fueron adquiridas diariamente durante el ciclo de crecimiento vegetativo. (Bricchet & Cabrera-Bosquet, 2017).

Cada imagen cuenta con una máscara de segmentación a nivel de píxel que distingue los píxeles de planta del fondo, constituyendo la única clase de anotación disponible: planta. En promedio, la planta ocupa el 4,08 % del área total de la imagen, aunque este porcentaje varía significativamente entre imágenes de plantas jóvenes y plantas adultas. El dataset incluye además un archivo complementario denominado *segmentationdata.csv* con metadatos por imagen: fecha de captura, ángulo de visión, altura de la cabina de imagen, número de planta y fecha de siembra.

Para el presente proyecto se trabaja con la muestra de descarga ofrecida por Dataset Ninja (476,84 MB), la cual constituye un subconjunto representativo del dataset completo. Esta decisión responde a criterios de viabilidad computacional en entornos sin GPU dedicada, sin comprometer la validez metodológica del análisis, dado que la muestra mantiene la distribución de ángulos, estados fenológicos y variabilidad morfológica del conjunto original.

4. Justificación

4.1 Segmentación de la planta

Separar los píxeles de la planta del fondo permite delimitar con precisión el objeto de interés y eliminar el ruido visual introducido por el sustrato, las estructuras de soporte o variaciones de iluminación. Sin ello, carecerán de validez, pues incluirá información del entorno.

En el contexto de la ingeniería agronómica, la segmentación precisa es condición necesaria para estimar el Índice de Área Foliar (IAF), variable correlacionada con la capacidad fotosintética del cultivo y, en consecuencia, con el rendimiento potencial. Asimismo, permite calcular métricas de biomasa aérea verde no destructivas.

4.2 Esqueletización de la planta

En plantas de maíz, el esqueleto revela el eje principal y los ejes foliares secundarios, proporcionando una descripción estructural de la arquitectura de la planta que no puede obtenerse directamente de la imagen original.

Desde el punto de vista agronómico, el análisis del esqueleto permite cuantificar la longitud de cada hoja y la distribución vertical de la biomasa foliar. Cultivos con hojas más erectas interceptan la luz de forma más uniforme, lo que justifica la selección de genotipos con determinadas arquitecturas foliares. En resumen, el esqueleto es una representación compacta y cuantificable de rasgos fenotípicos de alto valor selectivo.

4.3 Conteo de hojas

El número de hojas visibles en un momento dado es uno de los indicadores fenológicos más utilizados en el manejo agronómico del maíz. La escala V, definida por el número de hojas con collar visible, determina el momento óptimo para aplicaciones de herbicidas, insecticidas y fraccionamientos de nitrógeno. Errar en la determinación del estado V puede traducirse en pérdidas de eficiencia de hasta el 30 % en la respuesta a la fertilización nitrogenada y en daños fitotóxicos por herbicidas aplicados fuera de la ventana recomendada.

El conteo manual de hojas es lento e inconsistente entre distintos evaluadores, especialmente en las etapas tardías del cultivo. Un sistema automatizado basado en visión por computadora puede ejecutar este conteo en segundos por imagen, con precisión comparable o superior al experto humano, y hacerlo de forma completamente reproducible.

5. Metodología

La metodología se implementó íntegramente en Python 3 sobre Google Colab, haciendo uso de las bibliotecas *PlantCV*, *scikit-image*, *NumPy*, *Matplotlib* y *pandas*. Las imágenes fueron accedidas desde

Google Drive mediante la API de autenticación de Google Colab y se procesaron ocho imágenes de la muestra del dataset. El flujo de trabajo se estructuró en seis etapas secuenciales:

5.1 Carga y exploración de imágenes

Las imágenes se cargaron utilizando *matplotlib.image.imread()*. Se listaron todos los archivos con extensiones *.png*, *.jpg* y *.jpeg* dentro de la carpeta de trabajo mediante un ciclo iterativo con *os.listdir()*. Se visualizaron las primeras ocho imágenes en una cuadrícula 2×4 para una exploración visual preliminar.

5.2 Análisis de histogramas

Para cada una de las ocho imágenes se extrajo la banda roja (canal 0 del espacio RGB), convirtiéndola al rango 0–255 cuando los valores originales estaban normalizados en [0, 1]. Se calculó el histograma de intensidades mediante *numpy.histogram()* con 256 contenedores, y se trazó una línea vertical en la media de intensidad. Este análisis permitió identificar visualmente el umbral de separación planta-fondo para cada imagen de forma individual, guiando la selección de umbrales en la etapa de segmentación (Schar et al., 2016).

5.3 Segmentación por umbralización adaptativa

La segmentación se realizó mediante umbralización de la banda roja, aplicando la operación *np.where(Banda > umbral, 0, 1)*, donde los píxeles con intensidad superior al umbral se asignaron al fondo (0) y los de menor intensidad a la planta (1). Los umbrales fueron definidos individualmente para cada imagen con base en el análisis de histogramas previos, tomando valores entre 110 y 190. La decisión de segmentar por la banda roja responde a que el tejido vegetal verde presenta baja reflectancia en esta longitud de onda, generando un contraste natural con el fondo más claro de las imágenes (Schar et al., 2016).

5.4 Definición de ROI y operaciones morfológicas

Para cada imagen se definió una Región de Interés (ROI) específica, expresada como coordenadas (*y_min*, *y_max*, *x_min*, *x_max*), con el fin de enfocar el análisis en la zona de la planta y excluir bordes, macetas y estructuras de soporte. Sobre la imagen recortada al ROI se aplicaron operaciones morfológicas secuenciales utilizando *scikit-image.morphology* con un elemento estructurante tipo disco de radio 2 px: erosión binaria, dilatación binaria, apertura morfológica y cierre morfológico (dilatación seguida de erosión para cerrar huecos internos en la máscara).

5.5 Esqueletización y poda del esqueleto

Sobre cada máscara binaria refinada se generó el esqueleto de la planta mediante la función *pcv.morphology.skeletonize()* de *PlantCV* (Fahlgren et al., 2015), que implementa internamente el algoritmo de adelgazamiento morfológico de Zhang y Suen (1984). Las máscaras se convirtieron previamente al tipo *uint8* con valores 0 y 255, formato requerido por *PlantCV*. El esqueleto obtenido fue sometido a una poda mediante *pcv.morphology.prune()* con un tamaño mínimo de rama de 100 píxeles, eliminando ramas espurias de corta longitud que corresponden a ruido morfológico y no a hojas reales. La función *prune()* retorna el esqueleto podado, la imagen de segmentos coloreados y los objetos de aristas (*edge_objects*), estos últimos necesarios para la clasificación posterior de segmentos.

5.6 Análisis de morfología y conteo de hojas

Para la detección y conteo de hojas individuales se utilizó *pcv.create_labels()*, que etiqueta cada componente conectado de la máscara como un objeto independiente, separando hojas que no se tocan entre sí. El número de etiquetas generadas (*num_objs*) corresponde al conteo de hojas detectadas por imagen. Sobre cada objeto etiquetado se ejecutó *pcv.analyze.size()*, que calcula métricas morfométricas individuales: área (px²), perímetro, altura y anchura del rectángulo envolvente, y área del casco convexo (*convex hull*). Los resultados se exportaron mediante *pcv.outputs.save_results()* a un archivo CSV, que fue depurado con *pandas* mediante una tabla dinámica (*pivot_table*) para convertir el formato largo a un formato tabular legible (Fahlgren et al., 2015).

6. Resultados

El flujo de trabajo desarrollado permitió procesar satisfactoriamente las ocho imágenes seleccionadas del *Maize Whole Plant Image Dataset*, integrando segmentación, refinamiento morfológico, esqueletización y análisis de morfometría vegetal dentro de un flujo automatizado en Python. Sin embargo, el ruido de cada una de las imágenes que se tenían en el dataset, generaron problemas al momento del desarrollo, implicando que los resultados en el conteo de las hojas y como tal la separación no se hicieran de forma correcta. A continuación, se detallan los resultados según cada pasos implementados:

6.1 Segmentación de la planta

La segmentación basada en la banda roja del espacio RGB logró separar de manera adecuada la planta del fondo en la mayoría de las imágenes analizadas. El contraste natural entre el tejido vegetal y el fondo claro permitió obtener máscaras binarias funcionales mediante umbralización simple, especialmente en imágenes laterales con iluminación homogénea.

Las operaciones morfológicas posteriores (erosión, dilatación, apertura y cierre) mejoraron significativamente la calidad de las máscaras, eliminando artefactos pequeños y rellenando discontinuidades presentes en hojas delgadas. Esto permitió conservar la conectividad estructural de la planta y reducir el ruido antes de la esqueletización.

Sin embargo, se observaron diferencias importantes entre imágenes debido a variaciones de iluminación, orientación foliar y perspectiva de captura. Las imágenes tomadas desde ángulos laterales intermedios presentaron la mejor separación planta–fondo, mientras que las imágenes con superposición foliar o perspectivas cenitales mostraron mayores errores de segmentación.

6.2 Esqueletización y análisis estructural

La aplicación de la función `skeletonize()` de PlantCV permitió reducir las máscaras binarias a representaciones unidimensionales conservando la topología general de la planta. Los esqueletos obtenidos describieron correctamente el eje principal del tallo y las prolongaciones correspondientes a las hojas emergentes.

Posteriormente, la poda morfológica mediante `prune()` eliminó ramas cortas asociadas a ruido residual o irregularidades de segmentación, produciendo esqueletos más limpios y estructuralmente coherentes. Esta etapa fue determinante para disminuir falsas detecciones durante el conteo de componentes conectados.

En las plantas de mayor desarrollo vegetativo se observó un incremento notable en la complejidad del esqueleto debido a la superposición de hojas. En algunos casos, varias hojas quedaron conectadas como un único objeto, mientras que pequeñas discontinuidades generaron ramas artificiales adicionales.

6.3 Conteo de hojas y métricas morfológicas

El análisis morfológico realizado con `create_labels()` y `analyze.size()` permitió identificar componentes conectados y extraer métricas cuantitativas de cada objeto vegetal detectado. Entre las variables calculadas se incluyeron área foliar en píxeles, perímetro, longitud máxima, altura, anchura y área del casco convexo. Las áreas de los objetos variaron desde estructuras pequeñas asociadas a ruido residual hasta regiones extensas correspondientes al cuerpo principal de la planta. La variabilidad observada refleja diferencias fenológicas entre individuos y distintos niveles de complejidad estructural. Los resultados mostraron que el flujo de trabajo funciona de manera más estable en plantas jóvenes o medianamente desarrolladas, donde las hojas permanecen relativamente separadas. En contraste, en plantas con arquitectura más densa se incrementó la probabilidad de

subestimación o sobreestimación del número de hojas debido a oclusiones y fusiones entre estructuras foliares. A pesar de ello, el sistema genera errores supremamente grandes al momento de contabilizar las hojas en sí, pues genera valores completamente atípicos.

7. Discusión

La discusión confirma que el pipeline propuesto es una alternativa viable para el fenotipado automatizado de plantas de maíz mediante imágenes RGB y herramientas de código abierto, destacándose por no requerir GPU ni entrenamiento previo. El uso de PlantCV facilitó el análisis morfológico gracias a funciones especializadas como *skeletonize()*, *prune()* y *create_labels()* (Fahlgren et al., 2015). Sin embargo, la segmentación depende de umbrales manuales variables entre imágenes, lo que limita la escalabilidad del método y evidencia la necesidad de incorporar técnicas automáticas como Otsu, Niblack o modelos U-Net (Scharr et al., 2016). La principal limitación identificada fue la naturaleza bidimensional de las imágenes, ya que las oclusiones foliares generaron errores de conteo en plantas con arquitectura densa, un problema ampliamente reportado en sistemas de fenotipado 2D (Tardieu et al., 2017; Brichet et al., 2017). Además, se observó que el ángulo de captura influye directamente en la calidad del análisis: las vistas cenitales produjeron resultados inferiores respecto a las vistas laterales, coincidiendo con lo reportado por Brichet y Cabrera-Bosquet (2017), quienes destacan los ángulos de 60° y 120° como los más adecuados para separar visualmente las hojas.

8. Conclusiones

El presente proyecto demostró que es posible construir un pipeline funcional de segmentación, esqueletización y conteo de hojas en plantas de maíz utilizando Python, *PlantCV* y *scikit-image*, trabajando sobre la muestra del Maize Whole Plant Image Dataset (Brichet & Cabrera-Bosquet, 2017). Es importante señalar que, aunque el flujo de trabajo es funcional, los resultados presentan oportunidades de mejora. La eficacia de la segmentación está estrechamente ligada a las condiciones de captura: a pesar de trabajar en un entorno controlado sin fluctuaciones de iluminación, surgieron retos técnicos debido al tamaño de las plantas en relación con el espacio reducido y su interferencia con la estructura del lugar. Asimismo, la perspectiva de la fotografía resultó ser un factor determinante para el reconocimiento automatizado. Un claro ejemplo de esto fue la imagen 8, que al ser capturada desde un ángulo cenital (desde arriba), presenta mayores complicaciones para el procesamiento de datos en comparación con el resto de la muestra. Ambos retos son abordables con mejoras metodológicas concretas: umbralización automática (Otsu, Niblack) para el primero, y fusión multiangular de las 12 vistas disponibles en el dataset para el segundo.

La justificación agronómica del proyecto es sólida: el número de hojas es un indicador fenológico crítico para la toma de decisiones de manejo del maíz (Brichet et al., 2017), y su determinación automatizada tiene el potencial de transformar la fenotipificación de cultivos, reduciendo costos, eliminando sesgos de observador y escalando a dimensiones imposibles de abordar con métodos manuales (Tardieu et al., 2017). Las líneas de trabajo futuro incluyen: (i) incorporar segmentación semántica profunda (U-Net) para mejorar la robustez en estadios tempranos y condiciones variables de iluminación (Scharr et al., 2016); (ii) desarrollar la fusión multiangular para el conteo tridimensional de hojas; (iii) integrar datos temporales del dataset para construir curvas de crecimiento automatizadas por individuo; y (iv) validar el pipeline en condiciones de campo con imágenes.

9. Referencias

- Brichet, N., & Cabrera-Bosquet, L. (2017). *Maize whole plant image dataset [Dataset]*. Zenodo. <https://doi.org/10.5281/zenodo.1002675>
- Brichet, N., Fournier, C., Turc, O., Strauss, O., Artzet, S., Pradal, C., Welcker, C., Tardieu, F., & Cabrera-Bosquet, L. (2017). *A robot-assisted platform for high-throughput plant phenotyping*. *Plant Methods*, 13(1), 51. <https://doi.org/10.1186/s13007-017-0246-7>
- Fahlgren, N., Feldman, M., Gehan, M. A., Wilson, M. S., Shyu, C., Bryant, D. W., Hill, S. T., McEntee, C. J., Warnasooriya, S. N., Kumar, I., Ficor, T., Turnipseed, S., Gilbert, K. B., Brutnell, T. P., Carrington, J. C., Mockler, T. C., & Baxter, I. (2015). *A versatile phenotyping system and analytics platform reveals diverse temporal responses to water availability in Setaria*. *Molecular Plant*, 8(10), 1520–1535. <https://doi.org/10.1016/j.molp.2015.06.005>
- Scharr, H., Minervini, M., French, A. P., Klukas, C., Kramer, D. M., Liu, X., Luengo, I., Pape, J. M., Polder, G., Vukadinovic, D., Yin, X., & Tsafaris, S. A. (2016). *Leaf segmentation in plant phenotyping: A collation study*. *Machine Vision and Applications*, 27(4), 585–606. <https://doi.org/10.1007/s00138-015-0734-6>
- Tardieu, F., Cabrera-Bosquet, L., Pridmore, T., & Bennett, M. (2017). *Plant phenomics, from sensors to knowledge*. *Current Biology*, 27(15), R770–R783.
- Van der Walt, S., Schönberger, J. L., Nunez-Iglesias, J., Boulogne, F., Warner, J. D., Yager, N., Gouillart, E., & Yu, T. (2014). *scikit-image: Image processing in Python*. *PeerJ*, 2, e453.